

به نام خداوند بخشنده مهربان

آزمون میان ترم درس مبانی داده کاوی

دانشگاه صنعتی اصفهان- دانشکده مهندسی برق و کامپیوتر

ترم دوم سال ۱۴۰۴-۱۴۰۵

نام و نام خانوادگی شماره دانشجویی.....

لطفا به نکات زیر با دقت توجه بفرمایید:

- حتما نام و نام خانوادگی و شماره دانشجویی خود را در برگه پاسخ ثبت نمایید.
- در سوالات امتحان بر اساس رقم پنجم و ششم شماره دانشجویی خود، **مجموعه داده مربوط به خود** را استفاده کنید.
- (عدد دورقمی در جایگاه **پنجم و ششم** شماره دانشجویی خود را در نظر بگیرید باقیمانده تقسیم بر عدد ۴ آن را به دست آوردید و بر اساس آن مجموعه داده مرتبط با خود را انتخاب کنید. مثلا در شماره دانشجویی 40215753 دو رقم سوم عدد ۵۷ است و باقیمانده آن ۴ برابر ۱ است و به همین دلیل مجموعه داده شماره ۱ را برای حل مساله خود باید انتخاب کنید).
- بارم ها تقریبی هستند.
- پاسخ های کپی شده از منابع آماده، دارای نمره منفی خواهد بود؛ نمره کامل تنها به پاسخ هایی تعلق می گیرد که در آن استدلال شخصی دانشجو بر اساس سناریو مشهود باشد.
- پاسخ ها باید مستدل، کوتاه و خوانا نوشته شوند.
- زمان آزمون ۶۰ دقیقه است.

سوال ۱ (۲ نمره)

فرض کنید مدیر یک سایت فروشگاه آنلاین، داده های خرید کاربران را به شما داده است تا تحلیل کنید کدام کالاها با هم خریده می شوند.

- **الف (۱ نمره):** در مرحله «پیش پردازش» (Data Preprocessing)، یکی از کارهایی که باید انجام دهید این است که داده های نویزدار (مثل ثبت اشتباه مبلغ خرید یا خرید یک کاربر با چند کد کاربری مختلف) را تمیز کنید. اگر این کار را نکنیم، در مرحله استخراج قوانین انجمنی (Association Rules)، چه اتفاق بدی می افتد؟ (یک مثال بزنید).
- **ب (۱ نمره):** این پروژه در کدام مرحله از چرخه KDD قرار دارد و نقش اصلی آن چیست؟ (به صورت خلاصه و کاربردی).

سوال ۲ (۲ نمره)

ستون «مبلغ خرید» (Amount) برای الگوریتم Apriori عددی است و نمی‌توان مستقیماً از آن استفاده کرد.

- الف (۱ نمره): اگر بخواهید این ستون را به ۳ سطح {کم، متوسط، زیاد} تبدیل کنید، روشی را پیشنهاد دهید که بر اساس میانگین و انحراف معیار باشد. (فرمول ساده‌ای بنویسید).
 - ب (۱ نمره): چرا اصلاً تبدیل اعداد به دسته‌هایی مثل {کم، متوسط، زیاد} برای Apriori لازم است؟ اگر این کار را نکنیم و مستقیم سراغ اعداد برویم، چه مشکلی در پیدا کردن الگوها رخ می‌دهد؟ (تحلیل شما).
-

سوال ۳ (۳ نمره)

با توجه به مجموعه داده‌ی مخصوص خودتان (جدول انتهای سوالات):

- الف (۱.۵ نمره): جدول L_1 و L_2 را با کمینه پشتیبان (MinSupport) مشخص شده محاسبه کنید. (مراحل را مرحله به مرحله بنویسید).
 - ب (۱ نمره): اگر در مرحله پیدا کردن مجموعه‌های ۳ تایی، مجموعه $\{A, B, C\}$ را در نظر بگیرید، طبق خاصیت Apriori (Anti-monotonicity)، کدام زیرمجموعه‌های ۲ تایی این مجموعه حتماً باید قبلاً در L_1 و L_2 موجود بوده باشند تا اصلاً اجازه داشته باشیم $\{A, B, C\}$ را کاندید کنیم؟
 - ج (۰.۵ نمره): اگر بدانیم Support مجموعه $\{A, B\}$ از حد مجاز کمتر است، آیا لازم است وقتمان را برای بررسی $\{A, B, C\}$ تلف کنیم؟ چرا؟ (طبق همان خاصیت).
-

پیوست: مجموعه داده برای سوال ۳

کمینه پشتیبان برای ۵ تراکنش (MinSupport) برابر ۴۰٪ است. (یعنی باید حداقل ۲ بار تکرار شده باشد).

شماره	تراکنش‌ها
0	{Milk, Bread}, {Bread, Soap}, {Milk, Soap, Water}, {Bread, Milk, Soap}, {Milk, Water}
1	{Bread, Eggs}, {Milk, Water, Soap}, {Bread, Soap, Lemonade}, {Bread, Milk, Water}, {Bread, Milk, Eggs}
2	{Bread, Milk}, {Bread, Water}, {Milk, Soap, Lemonade}, {Bread, Milk, Soap}, {Milk, Soap}
3	{Bread, Lemonade}, {Bread, Soap, Eggs}, {Milk, Soap, Water}, {Bread, Milk, Water}, {Bread, Milk, Lemonade}